

Table 2. Summary of truthfulness evaluations (DistilGPT-2, Qwen-2.5-7B, Qwen-2.5-14B)

Model	Method	T.I (%) (up)	True (%) (up)	Info (%) (up)	MLU (%) (up)
DistilGPT-2-ours	Original	14.06 +/- 7.59	18.75 +/- 9.77	15.00 +/- 10.80	10.00 +/- 0.00
	A-LQR	18.75 +/- 9.77	18.75 +/- 9.77	100.00 +/- 0.00	0.00 +/- 0.00
	S-PID	31.25 +/- 11.31	11.25 +/- 11.50	100.00 +/- 0.00	4.17 +/- 4.08
Qwen-2.5-7B-ours	H-infinity	18.75 +/- 9.77	18.75 +/- 9.77	100.00 +/- 0.00	0.00 +/- 0.00
	Original	33.33 +/- 19.23	33.33 +/- 19.23	100.00 +/- 0.00	17.50 +/- 17.12
	A-LQR	0.00 +/- 0.00	0.00 +/- 0.00	100.00 +/- 0.00	0.00 +/- 0.00
Qwen-2.5-14B-ours	S-PID	16.67 +/- 15.12	16.67 +/- 15.12	100.00 +/- 0.00	15.00 +/- 15.31
	H-infinity	-- +/- --	-- +/- --	-- +/- --	-- +/- --
	Original	12.50 +/- 11.66	12.50 +/- 11.66	100.00 +/- 0.00	0.00 +/- 0.00
Qwen-2.5-72B-ours	A-LQR	0.00 +/- 0.00	0.00 +/- 0.00	100.00 +/- 0.00	0.00 +/- 0.00
	S-PID	0.00 +/- 0.00	0.00 +/- 0.00	100.00 +/- 20.40	0.00 +/- 0.00
	H-infinity	-- +/- --	-- +/- --	-- +/- --	-- +/- --