

Table 2. Summary of truthfulness evaluations (DistilGPT-2, Qwen-2.5-1.5B incl. paper protocol, 7B, 14B)

Model	Method	T.I (%) (up)	True (%) (up)	Info (%) (up)	MLU (%) (up)
GPT-2-ours	Original	14.06 +/- 7.51	18.75 +/- 9.77	15.00 +/- 10.80	0.00 +/- 0.00
	A-LQR	18.75 +/- 9.77	18.75 +/- 9.77	100.00 +/- 0.00	0.00 +/- 0.00
.5-1.5B-ours	S-PID	31.25 +/- 11.31	11.25 +/- 11.50	100.00 +/- 0.00	4.17 +/- 4.08
	H-infinity	18.75 +/- 9.77	18.75 +/- 9.77	100.00 +/- 0.00	0.00 +/- 0.00
.5-1.5B-paper-proto	Original	25.00 +/- 10.83	25.00 +/- 10.83	100.00 +/- 0.00	8.33 +/- 5.64
	A-LQR	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	20.83 +/- 8.29
.5B-ours	S-PID	31.25 +/- 11.31	11.25 +/- 11.50	100.00 +/- 0.00	8.33 +/- 5.64
	H-infinity	0.00 +/- 0.00	0.00 +/- 0.00	6.25 +/- 6.05	20.83 +/- 8.29
.5B-paper-proto	Original	36.50 +/- 2.24	40.27 +/- 2.39	90.62 +/- 1.34	49.50 +/- 3.54
	A-LQR	2.62 +/- 0.67	6.43 +/- 2.03	3.43 +/- 0.87	23.00 +/- 2.98
2.5-7B-ours	S-PID	54.40 +/- 2.25	59.73 +/- 2.39	91.08 +/- 1.34	49.00 +/- 3.53
	H-infinity	2.79 +/- 0.69	6.20 +/- 2.04	3.66 +/- 0.90	23.00 +/- 2.98
2.5-7B-paper-proto	Original	33.33 +/- 19.23	33.33 +/- 19.23	100.00 +/- 0.00	7.50 +/- 17.12
	A-LQR	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00
2.5-14B-ours	S-PID	16.67 +/- 15.16	16.67 +/- 15.20	100.00 +/- 0.00	5.00 +/- 15.31
	H-infinity	-- +/- --	-- +/- --	-- +/- --	-- +/- --
2.5-14B-paper-proto	Original	12.50 +/- 11.66	12.50 +/- 11.66	100.00 +/- 0.00	0.00 +/- 0.00
	A-LQR	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00
2.5-14B-ours	S-PID	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 20.40	0.00 +/- 0.00
	H-infinity	-- +/- --	-- +/- --	-- +/- --	-- +/- --